# 第6章: 物理数据库设计

Physical Database Design

#### 邹兆年

哈尔滨工业大学 计算机科学与技术学院 海量数据计算研究中心 电子邮件: znzou@hit.edu.cn

2020年春

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

1 / 56

# 教学内容1

- 物理数据库设计概述
- ② 索引的设计
- ③ 物理存储结构的设计

1课件更新于2020年3月16日

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

# 6.1 物理数据库设计概述 Introduction to Physical Database Design

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

3 / 56

# 物理数据库设计概述

- 任务: 在逻辑数据库设计的基础上,为每个关系模式选择合适的存储结构和存取方法,使得数据库上的事务能够高效率地运行
- 设计步骤:
  - ① 分析影响物理数据库设计的因素
  - ② 为关系模式选择存取方法
  - ③ 设计关系、索引等数据库文件的物理存储结构

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

· / 56

# 数据库负载(Workload)

- 查询列表
  - ▶ 查询语句
  - ▶ 出现频率
  - ▶ 性能要求
- 更新列表
  - ▶ 更新语句
  - ▶ 出现频率
  - ▶ 性能要求

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

5 / 56

# 设计步骤1:分析数据库负载

- 对于负载中的查询,需掌握以下信息
  - ▶ 查询涉及的关系
  - ▶ 投影属性
  - ▶ 选择条件和连接条件涉及的属性
  - ▶ 选择条件和连接条件的选择度(selectivity)
- 对于负载中的更新,需掌握以下信息
  - ▶ 被更新的关系
  - ▶ 更新的类型(增加、删除、修改)
  - ▶ 被更新关系上被更新的属性
  - ▶ 更新条件涉及的关系
  - ▶ 选择条件和连接条件涉及的属性
  - ▶ 选择条件和连接条件的选择度

# 设计步骤2: 选择关系数据库的存取方法

- 存取方法(access methods): DBMS访问关系中元组的方法
  - ▶ 顺序访问
  - ▶ 索引访问
- 索引(index)是提高查询效率的重要手段之一
  - ▶ 是否建立索引?
  - ▶ 将哪些属性作为索引的搜索键?
  - ▶ 建立什么类型的索引?
  - ▶ 使用哪种索引结构?
  - ▶ 索引更新代价如何?

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

7 / 56

# 设计步骤3:设计关系数据库的物理存储结构

- 确定如何在存储器上存储关系及索引,使得存储空间利用率最大 化,数据操作产生的系统开销最小化
- RDBMS使用的物理存储结构取决于存储引擎,用户可以选择合适的存储引擎,但基本不能改变存储引擎使用的物理存储结构

# 6.2 索引的设计

**Designing Indexes** 

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

0 / 56

# 索引(Index)

- 索引(index)能够帮助DBMS快速找到关系中满足搜索条件的元组
- 索引对于提高查询处理效率至关重要

### Example (索引)

索引		
Sname	元组地址	
Abby	addr <sub>3</sub>	
Ed	addr <sub>2</sub>	
Elsa	$addr_1$	
Nick	addr <sub>4</sub>	

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Student 关 糸					
Sno	Sname	Ssex	Sage	Sdept	
CS-001	Elsa	F	19	CS	
CS-002	Ed	М	19	CS	
MA-001	Abby	F	18	Math	
PH-001	Nick	М	20	Physics	

查询: SELECT Sdept FROM Student WHERE Sname = 'Elsa';

- 如果没有索引,则只能通过扫描Student关系来完成查询
- 如果有上述索引,则可以通过该索引来快速完成查询

### 索引的构成

- 索引键(index key): 索引根据一组属性(索引键)来定位元组
- 索引记录了元组的索引键值与元组地址的对应关系
- 索引项(index entry): 索引中的(键值, 地址)对
- 索引中的索引项按索引键值排序

## Example (索引)

索引		
Sname	元组地址	
Abby	addr <sub>3</sub>	
Ed	addr <sub>2</sub>	
Elsa	$addr_1$	
Nick	addr <sub>4</sub>	

地址  $addr_1$ addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Student 关 糸				
Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	М	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	М	20	Physics

邹兆年 (CS@HIT)

2020年春

11 / 56

### 索引的分类

- 主索引(primary index): 索引键是关系的主键
- 二级索引(secondary index): 索引键不是关系的主键

# Example (主索引vs 二级索引)

主索引

Sno	元组地址
CS-001	addr <sub>2</sub>
CS-002	addr <sub>3</sub>
MA-001	addr <sub>4</sub>
PH-001	$addr_1$

二级索引

Sdept	元组地址
CS	addr <sub>3</sub>
CS	addr <sub>2</sub>
Math	addr <sub>4</sub>
Physics	$addr_1$

地址

 $addr_1$  $addr_2$  $addr_3$ addr<sub>4</sub>

Student关系

	Sno	Sname	Ssex	Sage	Sdept
	CS-001	Elsa	F	19	CS
	CS-002	Ed	М	19	CS
	MA-001	Abby	F	18	Math
ĺ	PH-001	Nick	М	20	Physics

- 只能有一个主索引
- 可以有多个二级索引

邹兆年 (CS@HIT) 2020年春 12 / 56 第6章: 物理数据库设计

# 索引的分类(续)

- 唯一索引(unique index): 索引键值不重复
- 非唯一索引(non-unique index): 索引键值可重复

# Example (唯一索引vs 非唯一索引)

#### 唯一索引

Sno	元组地址
CS-001	addr <sub>2</sub>
CS-002	addr <sub>3</sub>
MA-001	addr <sub>4</sub>
PH-001	addr <sub>1</sub>

#### 非唯一索引

Sdept	元组地址
CS	addr <sub>3</sub>
CS	addr <sub>2</sub>
Math	addr <sub>4</sub>
Physics	$addr_1$

地址

addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr₄

#### Student关系

	Sno	Sname	Ssex	Sage	Sdept
	CS-001	Elsa	F	19	CS
Ì	CS-002	Ed	М	19	CS
	MA-001	Abby	F	18	Math
	PH-001	Nick	М	20	Physics

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

13 / 56

# 索引的分类(续)

- 索引中通常存储元组地址
- 根据元组地址读取元组需要进行1次I/O
- 为了节省I/O,可在索引中直接存储元组
- 聚簇索引(clustered index)/索引组织表(index-organized table): 索引中存储的是元组本身
- 非聚簇索引(non-clustered index): 索引中存储的是元组地址
- 一个关系上只能有一个聚簇索引(为什么?)

## Example (聚簇索引)

#### 聚簇索引

Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	М	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	М	20	Physics

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

# MySQL中的索引<sup>2</sup>

- 主索引采用聚簇索引
- 二级索引采用非聚簇索引
- 二级索引中存储的不是元组地址,而是元组的主键值 (好处? 坏处?)

# Example (MySQL中的主索引和二级索引)

二级索引

- 1/2 A1		
Sname	Sno	
Abby	MA-001	
Ed	CS-002	
Elsa	CS-001	
Nick	PH-001	

主索引

Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	М	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	М	20	Physics

<sup>2</sup>MySQL InnoDB存储引擎

邹兆年 (CS@HIT)

56章·物理数据库设计

2020年春 15 / 56

## 创建主索引

- 在CREATE TABLE或ALTER TABLE语句中使用PRIMARY KEY声明主键时,自动建立主索引
- 用ASC或DESC声明主索引中的属性按升序还是降序排列
- 只能在CREATE TABLE或ALTER TABLE语句中声明主索引
- 在MySQL中,主索引的名称就是PRIMARY

# Example (创建主索引)

CREATE TABLE Student (

Sno CHAR(6),

Sname VARCHAR(10),

Ssex ENUM('M', 'F'),

Sage INT,

Sdept VARCHAR(20),

PRIMIARY KEY (Sno ASC));

**◆□▶ ◆□▶ ◆■▶ ◆■▶ ■ か**990

### 创建二级索引

- 在CREATE TABLE或ALTER TABLE语句中声明二级索引 KEY | INDEX (索引键) [索引名]
- 用ASC或DESC声明索引属性的排序方式

```
Example (创建二级索引)

CREATE TABLE Student (
Sno CHAR(6) PRIMARY KEY,
Sname VARCHAR(10),
Ssex ENUM('M', 'F'),
Sage INT,
Sdept VARCHAR(20),
KEY (Sname, Sage DESC) key_sname_sage);
```

邹兆年 (CS@HIT)

第6章: 物理数据库设计

◆ロト ◆酉 ト ◆ 豊 ト ◆ 豊 ・ りへで

2020年春 17 / 56

# 创建唯一索引

- 在CREATE TABLE或ALTER TABLE语句中声明唯一索引 UNIQUE [KEY|INDEX] (索引键) [索引名]
- 用ASC或DESC声明索引属性的排序方式

#### Example (创建唯一索引)

```
CREATE TABLE Student (
Sno CHAR(6) PRIMARY KEY,
Sname VARCHAR(10),
Ssex ENUM('M', 'F'),
Sage INT,
Sdept VARCHAR(20),
UNIQUE (Sname) uk_sname);
```

第6章: 物理数据库设计

### 创建外键索引

- 在CREATE TABLE或ALTER TABLE语句中使用FOREIGN KEY声明外键时,会为外键创建索引
- 建外键索引是为了加快参照完整性检查

FOREIGN KEY (Sno) REFERENCES Student(Sno));

```
Example (创建外键索引)

CREATE TABLE SC (
Sno CHAR(6),
Cno CHAR(4),
Grade INT,
PRIMARY KEY (Sno, Cno),
```

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春 19 / 56

# 创建索引(续)

- 尽量在CREATE TABLE语句中将一个关系上的所有索引都建好
- 可以使用ALTER TABLE语句添加索引
- 除主索引外,可以使用CREATE INDEX语句添加索引 CREATE [UNIQUE] INDEX 索引名 ON 关系名 (索引键);

**◆□▶ ◆□▶ ◆■▶ ◆■ り**९@

### 删除索引

#### 删除二级索引

- 语句: DROP INDEX 索引名 ON 关系名;
- 删除二级索引不需要重新组织关系中的元组

#### 删除主索引

- 语句: DROP INDEX 'PRIMARY' ON 关系名;
- 删除主索引需要重新组织关系中元组
- 删除主索引的代价比删除二级索引的代价高

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

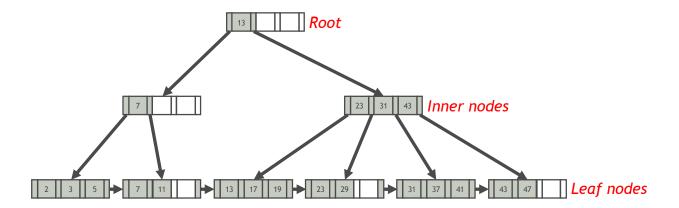
21 / 56

### 索引数据结构

- 索引可以用多种数据结构实现
  - ► B+树
  - ▶ 哈希表
  - ▶ 跳表(skiplist)
- 不同的索引结构具有不同的功能和特性

# B+树(B+ Trees)

- B+树是大多数RDBMS所使用的索引结构
- B+树是一棵平衡多叉树,所有叶节点的深度都相同
- 索引项全部存储在B+树的叶节点中,并按索引键值排序存储



邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

<ロ > < @ > < E > < E > の < で

23 / 56

# B+树索引支持的查询类型 |

对于B+树索引支持的查询,其查询结果中元组的索引键值在B+树的叶 节点中连续存储

### Example (B+树索引)

CREATE INDEX idx
ON Student (Sname, Sage, Ssex)
USING BTREE;

Sname	Sage	Ssex
Cindy	19	F
Ed	18	М
Elsa	19	F
Elsa	19	М
Elsa	20	F
Fawn	18	F

● 全值匹配: 和所有索引属性进行匹配

SELECT \* FROM Student
WHERE Sname = 'Elsa' AND Sage = 19 AND Ssex = 'F';

② 匹配最左前缀:和最前面几个索引属性进行匹配

SELECT \* FROM Student WHERE Sname = 'Elsa' AND Sage = 19;

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

#### B+树索引支持的查询类型 ||

③ 匹配属性前缀: 只匹配某属性的开头部分 SELECT \* FROM Student WHERE Sname LIKE 'E%';

4 范围匹配: 在给定范围内对某属性进行匹配

SELECT \* FROM Student
WHERE Sname BETWEEN 'Ed' AND 'Emma';

⑤ 精确匹配某一属性并范围匹配另一属性

SELECT \* FROM Student
WHERE Sname = 'Elsa' AND Sage BETWEEN 18 AND 20;

**6** B→树索引还支持按索引属性进行排序

Sname	Sage	Ssex
Cindy	19	F
Ed	18	М
Elsa	19	F
Elsa	19	М
Elsa	20	F
Fawn	18	F

邹兆年 (CS@HIT)

第6章·物理数据库设计

2020年春 25 / 56

## B+树索引的限制 |

如果查询结果中元组的索引键值在B+树的叶节点中不连续存储,则B+树不支持该查询

### Example (B+树索引)

CREATE INDEX idx
ON Student (Sname, Sage, Ssex)
USING BTREE;

Sname	Sage	Ssex
Cindy	19	F
Ed	18	М
Elsa	19	F
Elsa	19	М
Elsa	20	F
Fawn	18	F

■ 必须从索引的最左属性开始查找

SELECT \* FROM Student WHERE Sage = 19; 不能在该索引上执行这个查询

② 条件中不能包含表达式

### B+树索引的限制 ||

SELECT \* FROM Student

WHERE Sname = 'Elsa' AND 2020 - Sage = 2000;

在索引上只能根据条件Sname = 'Elsa'进行查找,在返回的元组 上验证条件2020 - Sage = 2000

③ 不能跳过索引中的属性

SELECT \* FROM Student

WHERE Sname = 'Elsa' AND Ssex = 'F';

在索引上只能根据条件Sname = 'Elsa'进行查找,在返回的元组 上验证条件Ssex = 'F'

● 如果查询中有关于某个属性的范围查询,则其右边所有属性都无法 使用索引查找(该限制条件并非在所有DBMS上都成立, MySQL可 以使用该索引在全部属性上做范围查询)

SELECT \* FROM Student WHERE Sname = 'Elsa'

AND Sage BETWEEN 18 AND 20 AND Ssex = 'F';

在索引上只能根据条件Sname = 'Elsa' AND Sage BETWEEN 18 AND 20进行查找,在返回的元组上验证条件Ssex = 'F'

邹兆年 (CS@HIT)

第6章: 物理数据库设计

# 哈希索引(Hash Index)

- 哈希索引是基于哈希表(hash table)实现的3
- 哈希表中的索引项是(索引键值的哈希值, 元组地址)
- 哈希索引只支持对所有索引属性的精确匹配

# Example (哈希索引)

哈着	台方	を引	1
クロク	N 7	<b>バノ</b>	1

h(Sname)	地址
111	addr <sub>2</sub>
222	addr <sub>4</sub>
333	addr <sub>3</sub>
444	$addr_1$

地址

 $addr_1$ addr<sub>2</sub> addr<sub>3</sub> addr₄

#### Student关系

Student > t A					
Sno	Sname	Ssex	Sage	Sdept	
CS-001	Elsa	F	19	CS	
CS-002	Ed	М	19	CS	
MA-001	Abby	F	18	Math	
PH-001	Nick	М	20	Physics	

- h('Abby') = 333
- h('Ed') = 111
- h('Elsa') = 444
- h('Nick') = 222

3MySQL中只有MEMORY存储引擎支持哈希索引,创建哈希索引时使用USING HASH

### 哈希索引的限制

CREATE INDEX idx ON Student (Sname, Sage, Sex) USING HASH;

- 哈希索引不支持部分索引属性匹配 SELECT \* FROM Student WHERE Sage = 19; (不能使用索引)
- 哈希索引只支持等值比较查询(=, IN),不支持范围查询
   SELECT \* FROM Student WHERE Sname = 'Elsa' AND Sage < 19 AND Ssex = 'F'; (不能使用索引)</li>
- 哈希索引并不是按照索引值排序存储的,所以无法用于排序
- 哈希索引存在冲突问题

◆□▶ ◆□▶ ◆■▶ ◆■ かへ○

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

29 / 56

# 索引设计的过程

- 分析工作负载
  - ▶ 分析SELECT语句和UPDATE语句涉及哪些关系
  - ▶ 分析WHERE子句、连接条件和GROUP BY子句中涉及哪些属性
- ② 依次检查每个重要的查询
  - ▶ 确定查询优化器为该查询制定的执行计划
  - ▶ 判断能否通过增加新的索引获得更高效的查询计划
    - ★ 需要了解索引技术(第7章)
    - ★ 需要了解查询优化技术(第9章)
  - ▶ 如果可以,将新的索引作为候选
- ◎ 权衡索引更新代价

# 设计技巧1: 伪哈希索引(Pseudo-Hash-Index)

• 尽管有些存储引擎不支持哈希索引,但我们可以模拟哈希索引

### Example (伪哈希索引)

在Student关系上创建Sname属性上的伪哈希索引

- ① 在Student中增加SnameHash属性,存储Sname属性的哈希值CRC32(Sname)
- ② 删除Sname上的索引,创建SnameHash上的索引
- 3 在查询时,对查询语句进行修改

SELECT \* FROM Student

WHERE Sname = 'Elsa' AND SnameHash = CRC32('Elsa');

伪哈希索引

 S.H.
 地址

 111
 addr2

 222
 addr4

 333
 addr3

 444
 addr1

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Sno	Sname	Ssex	Sage	Sdept	S.H.
CS-001	Elsa	F	19	CS	444
CS-002	Ed	М	19	CS	111
MA-001	Abby	F	18	Math	333
PH-001	Nick	М	20	Physics	222

Student关系

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

31 / 56

# 设计技巧1: 伪哈希索引(续)

- 优点: 查询速度快
- 缺点:
  - ▶ 仅支持等值查询,不支持范围查询
  - ▶ 需要改写查询
  - ▶ 需要在数据更新时维护哈希值属性

## Example (伪哈希索引)

伪哈希索引

S.H.	地址
111	addr <sub>2</sub>
222	addr <sub>4</sub>
333	addr <sub>3</sub>
444	addr <sub>1</sub>

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub> Student关系

Sno	Sname	Ssex	Sage	Sdept	S.H.
CS-001	Elsa	F	19	CS	444
CS-002	Ed	М	19	CS	111
MA-001	Abby	F	18	Math	333
PH-001	Nick	М	20	Physics	222

# 设计技巧2: 前缀索引(Prefix Index)

- 当索引很长的字符串时,索引会变得很大,而且很慢
- 当字符串的前缀(prefix)具有较好的选择性时,可以只索引字符串的前缀
  - ▶ 例: 'E', 'El', 'Els'都是'Elsa'的前缀

### Definition (索引的选择性(selectivity))

不重复的索引键值和元组数量N的比值,即 $\frac{\text{COUNT(DISTINCT A)}}{\text{COUNT(*)}}$ ,范围在1/N和1之间。选择性越高,索引的过滤能力越强。

#### Example (前缀索引,前缀长度=1,选择性=0.75)

CREATE INDEX idx1 ON Student (Sname(1));

前缀索引idx1  $\frac{Sname(1)}{A}$   $\frac{A}{addr_3}$   $\frac{B}{addr_1}$   $\frac{B}{A}$   $\frac{addr_2}{A}$   $\frac{addr_4}{A}$ 

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Student						
Sno	Sname	Ssex	Sage	Sdept		
CS-001	Elsa	F	19	CS		
CS-002	Ed	М	19	CS		
MA-001	Abby	F	18	Math		
PH-001	Nick	М	20	Physics		

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

33 / 56

# 设计技巧2: 前缀索引(续)

#### Example (前缀索引,前缀长度= 2,选择性= 1\*)

CREATE INDEX idx2 ON Student (Sname(2));

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Student Sno Sname Sdept Ssex Sage CS-001 F CS Elsa 19 CS-002 Ed CS 19 M F Math MA-001 Abby 18 PH-001 Nick Μ 20 **Physics** 

#### Example (前缀索引,前缀长度=3,选择性=1)

CREATE INDEX idx3 ON Student (Sname(3));

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Student Sno Ssex Sdept Sname Sage CS-001 F CS Elsa 19 CS CS-002 Ed M 19 MA-001 Abby F 18 Math PH-001 Nick M 20 **Physics** 

# 设计技巧2: 前缀索引(续)

#### 前缀索引的缺点

- 前缀索引不支持排序(ORDER BY)
- 前缀索引不支持分组查询(GROUP BY)

#### Example (前缀索引,前缀长度=1,选择性=0.75)

CREATE INDEX idx1 ON Student (Sname(1));

前缀索引idx1 Sname(1) 地址 A  $addr_3$  E  $addr_1$  E  $addr_2$  N  $addr_4$ 

地址 addr<sub>1</sub> addr<sub>2</sub> addr<sub>3</sub> addr<sub>4</sub>

Sno	Stude	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	М	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	М	20	Physics

#### Question

Sno属性上适合建前缀索引吗?有好办法吗?

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

35 / 56

# 设计技巧3: 单个多属性索引 vs. 多个单属性索引

SELECT \* FROM Student

WHERE Sname = 'Elsa' AND Sage = 19 AND Ssex = 'F';

#### 单个多属性索引

CREATE INDEX idx ON Student (Sname, Sage, Sex); 该索引能直接支持上面的查询

#### 多个单属性索引

CREATE INDEX idx1 ON Student (Sname);

CREATE INDEX idx2 ON Student (Sage);

CREATE INDEX idx3 ON Student (Sex):

- ① 在idx1上查找Sname = 'Elsa'的元组地址
- ② 在idx2上查找Sage = 19的元组地址
- ③ 在idx3上查找Ssex = 'F'的元组地址
- ❹ 索引合并(index merge): 对上述3个元组地址集合取交集,再取元组

邹兆年 (CS@HIT)

第6章: 物理粉据库设计

2020年春

# 设计技巧3: 单个多属性索引 vs. 多个单属性索引(续)

#### 多个单属性索引的缺点

- 效率没有在单个多属性索引上做查询高
- 索引合并涉及排序,要消耗大量计算和存储资源
- 在查询优化时,索引合并的代价并不被计入,故"低估"了查询代价

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春 3

37 / 56

# 设计技巧4: 索引属性的顺序

在属性Sname, Sage, Ssex上可以建立6种不同顺序的索引,哪种好?

- OREATE INDEX idx1 ON Student (Sname, Sage, Sex);
- ② CREATE INDEX idx2 ON Student (Sname, Ssex, Sage);
- OREATE INDEX idx3 ON Student (Sage, Sname, Sex);
- OREATE INDEX idx4 ON Student (Sage, Ssex, Sname);
- OREATE INDEX idx5 ON Student (Ssex, Sname, Sage);
- O CREATE INDEX idx6 ON Student (Ssex, Sage, Sname);

#### 经验法则

当不考虑排序(ORDER BY)和分组(GROUP BY)时,将选择性最高的属性放在最前面通常是好的,可以更快地过滤掉不满足条件的记录

### 设计技巧5: 聚簇索引

#### 优点

- 相关数据保存在一起,可以减少磁盘1/O
- 无需"回表",数据访问更快

#### 缺点

- 设计聚簇索引是为了提高I/O密集型应用的性能,如果数据全部在内存中,那么聚簇索引就没什么优势了
- 聚簇索引上元组插入的速度严重依赖于元组的插入顺序
- 更新聚簇索引键值的代价很高,需要将每个被更新的元组移动到新的位置
- 如果每条元组都很大,需要占用更多的存储空间,全表扫描变慢

### Example (聚簇索引)

聚簇索引

71=30E AT VT				
Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	М	19	CS
MA-001	Abby	F	18	Math
MA-002	Cindy	F	19	Math
PH-001	Nick	М	20	Physics

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

39 / 56

# 设计技巧5: 聚簇索引(续)

## 主键上建立聚簇索引

CREATE TABLE Student (

• 优点: 元组按Sno属性聚集存储

Sno CHAR(16) PRIMARY KEY, 。缺点:

Sname VARCHAR(10),

Ssex ENUM('M', 'F'),

Sage INT,

Sdept VARCHAR(20));

► 若不按Sno递增顺序插入元组,速度 会很慢

► 二级索引的索引项中存储Sno的值, 导致二级索引很大

### Example (主键上的聚簇索引)

二级索引

键值
4-001
5-002
5-001
H-001

聚簇索引

<b>水</b> 族					
Sno	Sname	Ssex	Sage	Sdept	
CS-001	Elsa	F	19	CS	
CS-002	Ed	М	19	CS	
MA-001	Abby	F	18	Math	
PH-001	Nick	М	20	Physics	

# 设计技巧5: 聚簇索引(续)

#### 代理键(surrogate key)上建立聚簇索引

CREATE TABLE Student (

Sno CHAR(16),

Sname VARCHAR(10),

Ssex ENUM('M', 'F'),

Sage INT,

Sdept VARCHAR(20),

ID INT AUTO\_INCREMENT,

PRIMARY KEY (ID));

- · 主键ID与应用无关, 称为代理键
- 优点:
  - ▶ 一定按ID递增顺序插入记录,插入速度快
  - ► 二级索引的索引项中存储ID的值,二级索引更小
- 缺点: 记录不按Sno属性聚集存储

Ssex

F

M

F

M

Sage

19

20

18

19

### Example (代理键上的聚簇索引)

二级索引

邹兆年 (CS@HIT)

#### Student (聚簇索引)

Sname

Elsa

Nick

Abby Ed

		•		
Sname	ID		ID	Sno
Abby	3		1	CS-001
Ed	4		2	PH-001
Elsa	1		3	MA-001
Nick	2		4	CS-002

第6音· 物理数据库设计

2020年春

Sdept

CS

**Physics** 

Math

CS

41 / 56

### 设计技巧6:覆盖索引

### Definition (覆盖索引)

如果一个索引包含(覆盖)一个查询需要用到的所有属性,则称该索引为覆盖索引(covering index)

## Example (覆盖索引)

• 查询: SELECT Sno FROM Student WHERE Sname = 'Elsa';

• 索引: CREATE INDEX idx ON Student (Sname, Sno);

• 索引idx能够覆盖上述查询

覆盖索引

Sname	Sno	地址 地址
Abby	MA-001	$addr_3$ $addr_1$
Ed	CS-002	$addr_2$ $addr_2$
Elsa	CS-001	addr <sub>1</sub> addr <sub>3</sub>
Nick	PH-001	addr <sub>4</sub> addr <sub>4</sub>

Student

Sno	Sname	Ssex	Sage	Sdept
CS-001	Elsa	F	19	CS
CS-002	Ed	М	19	CS
MA-001	Abby	F	18	Math
PH-001	Nick	М	20	Physics

# 设计技巧6: 覆盖索引(续)

- 索引项数量通常远小于元组数量,如果只需访问覆盖索引,则可以极大减少数据访问量
- 覆盖索引中属性值是顺序存储的,能更快找到满足条件的属性值
- 使用覆盖索引,则无需回表

### Example (覆盖索引)

• 查询: SELECT Sno FROM Student WHERE Sname = 'Elsa';

• 索引: CREATE INDEX idx ON Student (Sname, Sno);

• 索引idx能够覆盖上述查询

覆盖索引				
Sname	Sno	地址地址		
Abby	MA-001	addr <sub>3</sub> addr <sub>1</sub>		
Ed	CS-002	addr <sub>2</sub> addr <sub>2</sub>		
Elsa	CS-001	$addr_1$ $addr_3$		
Nick	PH-001	addr₄ addr₄		

Sno	Student Sname Ssex Sage Sdept				
CS-001	Elsa	F	19	CS	
CS-002	Ed	М	19	CS	
MA-001	Abby	F	18	Math	
PH-001	Nick	М	20	Physics	

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

43 / 56

# 设计技巧6: 覆盖索引(续)

即使一个索引不能覆盖某个查询,我们也可以将该索引用作覆盖索引,并采用延迟连接(deferred join)方式改写查询

## Example (延迟连接)

- 查询: SELECT \* FROM Student WHERE Sname = 'Elsa';
- 索引: CREATE INDEX idx ON Student (Sname, Sno);
- 索引idx不能覆盖上述查询,但我们可以将该查询改写为 SELECT \* FROM Student NATURAL JOIN (SELECT Sno FROM Student WHERE Sname = 'Elsa') R;
- 可以利用覆盖索引快速执行子查询(延迟连接什么情况下有用?)

<i>8</i>	<b>豊盖索引</b>		_
Sname	Sno	地址	地址
Abby	MA-001		$addr_1$
Ed	CS-002	addr <sub>2</sub>	
Elsa	CS-001		addr <sub>3</sub>
Nick	PH-001	addr <sub>4</sub>	addr <sub>4</sub>

Student						
Sno	Sname Ssex Sage Sdept					
CS-001	Elsa	F	19	CS		
CS-002	Ed	М	19	CS		
MA-001	Abby	F	18	Math		
PH-001	Nick	M	20	Physics		

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

### 避免不合理地使用索引

- 一方面要设计好的索引,另一方面要避免不合理地使用索引
- 若不合理地使用索引,则不但不会让查询变快,反而会使查询变慢

#### Example (类型转换)

- Student关系的Sno属性是字符串型
- Sno属性上建了主索引
- 下面的查询变慢了SELECT \* FROM Student WHERE Sno = 123456;
- 原因:
  - DBMS不会使用主索引,而要进行全表扫描
  - ② 因为Sno属性值为字符串,需要转换为整型

◆□▶ ◆□▶ ◆壹▶ ★壹▶ 壹 かへ○

邹兆年 (CS@HIT)

第6章:物理数据库设计

2020年春

45 / 56

## 查询改写

- 查询优化器不能保证总是找到好的查询计划
- 用户不能给DBMS指定查询计划
- 用户只能通过添加索引或改写查询来影响查询优化器的决策
- 如果基于现有索引对查询进行改写就能获得好的查询计划,就没必要添加新的索引
- 如何改写查询取决于查询优化器的实现

#### Example (查询改写)

SELECT Sno, Sname FROM Student WHERE Ssex = 'F' OR Sage = 19;

如果在Ssex和Sage上分别建有索引,则可以将该查询改写为

(SELECT Sno, Sname FROM Student WHERE Ssex = 'F') UNION (SELECT Sno, Sname FROM Student WHERE Sage = 19);

第6章: 物理数据库设计

2020年春

# 6.3 物理存储结构的设计

Design of Physical Storage Structures

**◆□▶◆□▶◆壹▶◆壹▶ 壹 か**900

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

47 / 56

### 数据类型的选择

• 选择合理的数据类型对于提高数据库系统的性能非常重要

#### 选择数据类型的原则

- 尽量使用可以正确存储数据的最小数据类型
  - ▶ 原因: 最小数据类型占用空间更少,处理速度更快
  - 例: INTEGER或INT占4字节; SMALLINT占2字节; TINYINT占1字节; MEDIUMINT占3字节; BIGINT占8字节
  - 例:使用VARCHAR(5)和VARCHAR(100)来存储'hello'的空间开销是一样的;但在排序时,MySQL会按照类型分配固定大小的内存块
- ② 尽量选择简单的数据类型
  - ▶ 原因: 简单数据类型的处理速度更快
  - ▶ 例: 用DATE、DATETIME等类型来存储日期和时间,不要用字符串
  - ▶ 例: 用整型来存储IP地址,而不是用字符串
- ③ 若无需存储空值,则最好将属性声明为NOT NULL
  - 原因: 含空值的属性使得索引、统计、比较都更复杂

◆□ → ◆□ → ◆ ≥ → ◆ ≥ → りへの

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春 48

### 标识符类型的选择

- 为标识符属性选择合适的数据类型非常重要
  - ▶ 标识符属性通常会被当作索引属性,频繁地进行比较
  - ▶ 标识符属性通常会被当作主键或外键,频繁地进行连接
  - ▶ 在设计时,既要考虑标识符属性类型占用的空间,还要考虑比较的效率
- 整型: 最好的选择
  - ▶ 占用空间少
  - ▶ 比较速度快
  - ▶ 可声明为AUTO\_INCREMENT,为应用提供便利
- ENUM和SET类型: 糟糕的选择
  - ▶ MySQL内部用整型来存储ENUM和SET类型的值,占用空间少
  - ▶ 在比较时会被转换为字符串,比较速度慢
- 字符串型: 糟糕的选择
  - ▶ 占用空间大
  - ▶ 比较速度慢

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

49 / 56

### 关系模式的设计

• 一个关系不要包含太多属性,可以纵向拆分为多个关系

$$R(ID, A_1, A_2, \dots, A_{1000})$$

• 不要使用"实体-属性-值(EAV)"设计模式(即为实体的每个属性建立 一个关系),因为在这种关系数据库模式上要进行大量连接

$$R_1(ID, A_1)$$

 $R_2(ID, A_2)$ 

. . .

 $R_{1000}(ID, A_{1000})$ 

• 可以进行合理的S纵向拆分

$$R_1(ID, A_1, A_2, \ldots, A_{50})$$

$$R_2(ID, A_{51}, A_{52}, \dots, A_{100})$$

. . .

$$R_{20}(ID, A_{951}, A_{952}, \dots, A_{1000})$$

# 关系模式的纵向划分(Vertical Partitioning)

• 根据工作负载对关系模式进行纵向划分

#### Example (关系模式的纵向划分)

关系模式Student(Sno, Sname, Ssex, Sage, Sdept, Balance)

- Balance表示学生校园账户的余额,频繁变化
- 经常按系查询学号和姓名

可以将Student划分为三个关系模式R1(Sno, Sname, Ssex, Sage), R2(Sno, Sdept), R3(Sno, Balance)

- 可以在更小的关系R2上更快地按系查询学号和姓名
- 在R3上更新Balance时,与R1和R2上的并发查询不产生冲突

◆ロト ◆団 ト ◆ 豊 ト ◆ 豊 ・ りへ○

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

51 / 56

# 关系模式的横向划分(Horizontal Partitioning)

• 根据工作负载,将关系中的元组划分到多个具有相同模式的关系中

#### Example (关系模式的横向划分)

关系模式Student(Sno, Sname, Ssex, Sage, Sdept)上查询的WHERE子句中经常含有Sdept = val的条件

- 将Student中的元组按Sdept属性值划分到不同关系中,如CS\_Student, MA\_Student, PH\_Student
- 将含有条件Sdept = 'CS'的查询改写成CS\_Student关系上的查询
- 创建视图Student

CREATE VIEW Student AS (

(SELECT \* FROM CS\_Student) UNION

(SELECT \* FROM MA\_Student) UNION

(SELECT \* FROM PH\_Student));

• 全体学生上的查询在视图Student上完成

第6章: 物理数据库设计

第6章

#### 总结

- 物理数据库设计的步骤
- ② 索引的设计
  - ▶ 索引的构成
  - ▶ 索引的分类
  - ▶ 索引数据结构
  - ▶ 索引设计技巧
  - ▶ 查询改写
- ③ 物理存储结构的设计
  - ▶ 数据类型的选择
  - ▶ 数据库的划分

《□ ▶ 《□ ▶ 《 亘 ▶ ○ 夏 ○ 夕 ♀ ◎

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春

53 / 56

#### 练习 |

使用test\_index.sql在MySQL上创建一个数据库

- ① 使用show index命令查看该数据库上创建了哪些索引
- ② 使用explain命令分析MySQL如何执行下列查询,验证索引的作用
  - ① SELECT \* FROM Foo WHERE b = 123 AND c = 23;
  - 2 SELECT \* FROM Fooldx WHERE b = 123 AND c = 23;
  - 3 SELECT \* FROM Foo WHERE b = 123;
  - SELECT \* FROM Fooldx WHERE b = 123;
  - SELECT \* FROM FooIdx WHERE c = 23;
  - SELECT \* FROM Foo WHERE tag LIKE '00123%';
  - SELECT ★ FROM Fooldx WHERE tag LIKE '00123%';
  - 3 SELECT \* FROM Foo WHERE b BETWEEN 123 AND 234;
  - SELECT \* FROM Fooldx WHERE b BETWEEN 123 AND 234;
  - SELECT \* FROM Fooldx
    WHERE b = 123 AND c BETWEEN 23 AND 45;
  - SELECT \* FROM Fooldx WHERE b = 123 AND c + 1 = 24;
  - SELECT \* FROM Fooldx WHERE a = 1234 AND c = 34;

#### 练习 ||

- SELECT \* FROM Fooldx
  WHERE a = 1234 AND b BETWEEN 234 AND 345 AND c = 34;
- SELECT \* FROM Fooldx WHERE tag LIKE '00123%';
- ⑤ SELECT \* FROM Fooldx WHERE tag LIKE '0012%';
- SELECT ★ FROM Fooldx WHERE tag LIKE '001234%' OR b = 56;
- SELECT a FROM Fooldx WHERE b = 123;
- SELECT id FROM Fooldx WHERE b = 123;
- ③ 通过分析EXPLAIN结果中key和key\_len的值,说明以下查询是按照什么属性在索引上进行查找的:
  - ► SELECT \* FROM Fooldx WHERE id = 1234;
  - ► SELECT \* FROM Fooldx WHERE a = 1234;
  - ► SELECT \* FROM Fooldx WHERE b = 123 AND c + 1 = 24;
  - ► SELECT \* FROM Fooldx WHERE a = 1234 AND c = 34;
  - ► SELECT \* FROM Fooldx WHERE a = 1234 AND b BETWEEN 234 AND 345 AND c = 34;

邹兆年 (CS@HIT)

第6章: 物理数据库设计

2020年春 !

55 / 56

# 参考资料

 Baron Schwartz, Peter Zaitsev, Vadim Tkachenko. High Performance MySQL.